

KỊCH BẢN THUYẾT TRÌNH BÁO CÁO TIẾN ĐỘ & PHẢN BIỆN ĐỀ TÀI (15 PHÚT CHUẨN)

- **Người hướng dẫn:** ThS. Cáp Đình La Thăng
- **Học viên / Sinh viên:** Nguyễn Đức Ý (MSSV: 25730094)
- **Đề tài:** *Predicting Financial Distress in US Retailers from SEC XBRL Disclosures*
- **Thời lượng:** Đúng 15 phút (00:00 – 15:00)

BẢNG PHÂN PHỐI THỜI GIAN CHUẨN (TỔNG: ĐÚNG 15:00)

STT	Slide	Tiêu đề slide	Thời lượng	Mốc thời gian
1	Slide 1	Trang bìa & Đặt vấn đề	01:00	00:00 – 01:00
2	Slide 2	Input & Output Specifications	01:15	01:00 – 02:15
3	Slide 3	Corpus Architecture & Purged Time-Split	01:15	02:15 – 03:30
4	Slide 4	Dual-Level Imbalance Paradox	01:30	03:30 – 05:00
5	Slide 5	Feature Signals & Multicollinearity	01:15	05:00 – 06:15
6	Slide 6	Data Preprocessing & MNAR Mechanism	01:15	06:15 – 07:30

7	Slide 7	Four Family Model Benchmarking	01:30	07:30 – 09:00
8	Slide 8	Confusion Matrix & Error Audit	01:15	09:00 – 10:15
9	Slide 9	Cost-Sensitive Threshold Optimization	01:30	10:15 – 11:45
10	Slide 10	47-Feature Taxonomy & Ablation Study	01:15	11:45 – 13:00
11	Slide 11	Entity Shortcut Leakage (DeLong & LOCO)	01:15	13:00 – 14:15
12	Slide 12	Kết luận & Lời cảm ơn	00:45	14:15 – 15:00

NỘI DUNG CHI TIẾT KỊCH BẢN THUYẾT TRÌNH

SLIDE 1: TRANG BÌA & ĐẶT VẤN ĐỀ (00:00 – 01:00)

- **Thời lượng:** 01 phút.
- **Phong thái:** Điềm đạm, tự tin, kính trọng.

"Kính thưa Thầy ThS. Cáp Đình La Thăng, em là Nguyễn Đức Ý, học viên thuộc Nhóm 18. Hôm nay, em xin phép được báo cáo chi tiết với Thầy kết quả nghiên cứu của đề tài: **'Dự đoán Kiệt quệ Tài chính ở các Chuỗi Bán lẻ Hoa Kỳ từ Báo cáo Công bố SEC XBRL'** (*Predicting Financial Distress in US Retailers from SEC XBRL Disclosures*).

Xuất phát từ những định hướng ban đầu của Thầy về việc xây dựng một hệ thống cảnh báo sớm có khả năng giải thích và kiểm toán thực chứng, nghiên cứu này không thuần túy là việc áp dụng các mô hình học máy đóng gói sẵn. Trọng tâm của đề tài là giải quyết ba thách thức cốt lõi trong dữ liệu chuỗi thời gian tài chính:

1. Triệt tiêu triệt để rò rỉ thông tin trước công bố (*Look-ahead Bias*).
2. Xử lý triệt để hàm tổn thất bất đối xứng trong nghiệp vụ kiểm toán.
3. Chứng minh thực nghiệm hiện tượng 'học vẹt danh tính doanh nghiệp' (*Entity*

Memorization Shortcut) vốn đang khiến nhiều mô hình học máy đạt điểm kiểm định rất cao trên giấy tờ nhưng sụp đổ khi triển khai thực tế.

Sau đây, em xin phép đi vào chi tiết kỹ thuật của hệ thống."

SLIDE 2: INPUT & OUTPUT SPECIFICATIONS (01:00 – 02:15)

- **Thời lượng:** 01 phút 15 giây.
- **Tập trung:** Ranh giới phạm vi dữ liệu, tính *Point-in-Time*.

"Thưa Thầy, ở khâu xác lập bài toán, em tuân thủ nghiêm ngặt nguyên tắc đóng băng ranh giới thông tin.

Về **Đầu vào (Input Specification)**:

- Hệ thống khai thác **16 chỉ tiêu tài chính nguyên bản** từ các báo cáo định kỳ 10-K và 10-Q của 8 chuỗi bán lẻ lớn tại Mỹ. Dữ liệu trải dài trên tổng cộng **332 quý báo cáo tài chính**, với mỗi doanh nghiệp có từ 32 đến 48 quý quan sát liên tục. Toàn bộ các mốc thời gian đều bị ràng buộc chặt chẽ bởi điều kiện *Point-in-Time*: thời điểm thông tin khả dụng trên cổng EDGAR phải diễn ra trước hoặc đúng bằng ngày chốt sổ quan sát ($available_on \leq as_of$).
- Từ 16 chỉ tiêu gốc, em xây dựng **47 tỷ số tài chính đa chu kỳ** qua các cửa sổ trượt lên đến 8 quý, bao gồm: khả năng thanh toán, đòn bẩy vốn, biên lợi nhuận, biến động YoY và các ngưỡng cực trị lịch sử.
- Đặc biệt, đúng như Thầy đã lưu ý, em **loại trừ hoàn toàn** giá cổ phiếu, chỉ số kinh tế vĩ mô và xếp hạng tín nhiệm, đồng thời nghiêm cấm kỹ thuật one-hot mã chứng khoán (ticker) để loại bỏ mọi đường tắt phi kế toán.

Về **Đầu ra (Output Specification)**:

- Nhãn mục tiêu $\$Y \in \{0, 1\}$ được xác định rõ: 0 là Lành mạnh và 1 là Kiệt quệ tài chính trong quý tiếp theo.
- Điểm số rủi ro $\$P(\text{distress}) \in [0, 1]$ được trích xuất từ tỷ lệ bỏ phiếu của quần thể cây rừng ngẫu nhiên (Random Forest). Điểm số thô này sẽ được ánh xạ qua một ngưỡng vận hành thực nghiệm $t = 0.788$ nhằm tối ưu hóa chi phí kiểm toán dưới hàm phạt bất đối xứng."

SLIDE 3: CORPUS ARCHITECTURE & PURGED TIME-SPLIT (02:15 – 03:30)

- **Thời lượng:** 01 phút 15 giây.
- **Tập trung:** Thiết kế Purged Buffer 90 ngày, băm SHA-256.

"Thưa Thầy, nhằm đảm bảo dữ liệu không xảy ra bất kỳ hiện tượng rò rỉ nào qua trục thời gian, kiến trúc phân chia tập dữ liệu được thiết kế theo mô hình **Purged Time-Split** 4 giai đoạn:

- Toàn bộ vũ trụ nghiên cứu gồm **332 quý báo cáo** của 8 tập đoàn bán lẻ (DG, DKS, FIVE, HD, LOW, ORLY, ROST, WMT), được biến đổi qua các cửa sổ trượt 8 quý để tạo thành ma trận **324 mẫu quan sát**.
- Trong ma trận này, từng ô dữ liệu đều được kiểm toán đối chiếu nguồn gốc, đạt độ toàn vẹn tuyệt đối với **0 sai lệch mã băm SHA-256**.
- Cấu trúc phân rã thời gian gồm:

1. **Training Set (212 mẫu):** Tỷ lệ dương tính khiết quệ 62.3%, dùng để huấn luyện tham số nội bộ.
2. **Purged Buffer (16 mẫu):** Đây là **vùng cách ly 90 ngày** được thiết lập nghiêm ngặt ngay sau tập huấn luyện. Vùng đệm này nhằm hấp thụ toàn bộ độ trễ nộp báo cáo thực tế của các doanh nghiệp, ngăn chặn triệt để hiện tượng dữ liệu tương lai rò rỉ vào quá khứ.
3. **Validation Set (32 mẫu):** Tỷ lệ dương tính 65.6%, dành riêng cho việc tìm ngưỡng quyết định chi phí.
4. **Locked Test Set (64 mẫu):** Tỷ lệ dương tính 59.38%, bị khóa hoàn toàn và chỉ mở ra một lần duy nhất để đánh giá năng lực ngoại suy ngoài trục thời gian (*Out-of-Time*)."

SLIDE 4: DUAL-LEVEL IMBALANCE PARADOX (03:30 – 05:00)

- **Thời lượng:** 01 phút 30 giây.
- **Tập trung:** Nghịch lý mất cân bằng 2 tầng, entropy đánh lừa.

"Thưa Thầy, Slide số 4 thể hiện một phát hiện thực nghiệm rất then chốt mà em đã ghi nhận được trong quá trình làm sạch dữ liệu: **Nghịch lý Mất cân bằng Hai tầng (Dual-Level Imbalance Paradox)**.

Ở Tầng 1 - Cấp độ Quan sát Tổng thể (Sample Observations):

- Khi nhìn vào toàn bộ mẫu, bài toán tưởng như phân phối rất điều hòa: Tỷ lệ mất cân bằng chỉ là 1.66, tỷ lệ khiết quệ là 62.35%, và độ hỗn loạn Shannon Entropy lên tới **0.9556 bit** (gần tiệm cận mức tối đa 1.0 bit).
- Nếu một người làm khoa học dữ liệu vội vã nhìn vào các chỉ số vĩ mô này, họ sẽ lập tức kết luận đây là một tập dữ liệu cân bằng lý tưởng.

Tuy nhiên, khi đào sâu xuống **Tầng 2 - Cấp độ Thực thể Doanh nghiệp (Entity Concentration)**:

- Bức tranh hoàn toàn bị méo mó. Các chuỗi bán lẻ thể hiện tính kiên định trạng thái mang tính tiền định. Cụ thể: **Home Depot (HD)**, **Lowe's (LOW)** và **Walmart (WMT)** khiết quệ tuyệt đối 100% qua các quý khảo sát; trong khi **Ross Stores (ROST)** lại duy trì tỷ lệ khiết quệ vồn vẹn 4.7%.
- Điều này dẫn tới việc **41.0% tổng dung lượng corpus bắt nguồn từ các doanh nghiệp thuần đơn nhân**.
- Đây chính là nguồn cơn của lỗ hổng 'học vẹt': mô hình rất dễ học các đặc trưng tĩnh của một công ty để gán nhãn cố định thay vì học quy luật động học tài chính thực sự."

SLIDE 5: FEATURE SIGNALS & MULTICOLLINEARITY (05:00 – 06:15)

- **Thời lượng:** 01 phút 15 giây.
- **Tập trung:** Xếp hạng đặc trưng, sụp đổ số chiều (Dimensionality Collapse).

"Thưa Thầy, bước sang khâu phân tích tín hiệu đặc trưng và tương quan nội tại:

- Qua kiểm định độ quan trọng hoán vị (*Permutation Importance*), đặc trưng đứng vị trí số 1 toàn diện là **gross_margin_latest** với mức suy giảm $\Delta \text{AUROC} = +0.008\%$. Kết quả này hoàn toàn nhất quán với bản chất kinh tế của ngành bán lẻ: các chuỗi siêu thị vận hành trên biên lợi nhuận mỏng, do đó năng lực định giá và kiểm

soát giá vốn hàng bán chính là lá chắn sống còn quyết định khả năng kiệt quệ tài chính.

- Mặt khác, khi tiến hành kiểm toán đa cộng tuyến, em ghi nhận hiện tượng **sụp đổ số chiều (Dimensionality Collapse)** rất trầm trọng:
 - Có tới **33 trên tổng số 47 đặc trưng** sở hữu hệ số phóng đại phương sai $\text{VIF} > 10$.
 - Mức lạm phát phương sai cao kỷ lục ghi nhận được lên tới **798.10**.
 - Khi đo lường qua tỷ số tham gia ma trận tương quan (*Participation Ratio*), **47 chỉ tiêu tài chính danh nghĩa thực chất chỉ trải trên 12.89 tọa độ tuyến tính độc lập**.
- Điều này khẳng định không gian đặc trưng chứa đựng lượng dư thừa thông tin khổng lồ, đòi hỏi thuật toán phải có cơ chế chọn lọc nhánh cây đủ vững chãi trước hiện tượng đồng tuyến tính."

SLIDE 6: DATA PREPROCESSING & MNAR MECHANISM (06:15 – 07:30)

- **Thời lượng:** 01 phút 15 giây.
- **Tập trung:** Kiểm toán 5.312 ô dữ liệu, cơ chế MNAR (–55.7 pp).

"Thưa Thầy, quy trình tiền xử lý được chuẩn hóa qua 5 bước kiểm soát chất lượng từ báo cáo 10-K/10-Q thô đến ma trận mô hình 47 biến chuẩn hóa.

Tại bước số 4 - Kiểm toán giá trị khuyết thiếu, em xin phép làm rõ cấu trúc dữ liệu theo đúng hồ sơ xuất xứ (*Provenance Audit*):

 - Toàn bộ bảng dữ liệu gồm **5.312 ô giá trị** (tương ứng 332 quý nhân 16 chỉ tiêu). Trong đó, có đúng **703 ô bị thiếu dữ liệu** từ gốc do doanh nghiệp không công bố mục kế toán đó, và **4.609 ô dữ liệu có đầy đủ sự kiện** được xác thực, tra cứu ngược thành công. 703 ô thiếu này tách biệt hoàn toàn chứ không nằm trong 4.609 ô đã kiểm toán.
 - Phân tích chuyên sâu cho thấy 703 giá trị khuyết này tuân theo cơ chế **Thiếu Không Ngẫu Nhiên (Missing Not At Random - MNAR)**. Cụ thể, việc không công bố chỉ tiêu biên lợi nhuận ròng tập trung chủ yếu ở các doanh nghiệp có sức khỏe tài chính lành mạnh.
 - Độ chênh lệch phân tách nhãn (*Distress Class Separation Delta*) đạt mức **\$-55.7\$ điểm phần trăm** ($-\$55.7 \text{ pp}$). Đây là bằng chứng cho thấy hành vi khuyết báo cáo tài chính là một tín hiệu thông tin nội sinh chứ không phải nhiễu ngẫu nhiên, giúp giải thích vì sao các thuật toán cây xử lý giá trị khuyết tự nhiên lại có ưu thế."

SLIDE 7: FOUR FAMILY MODEL BENCHMARKING (07:30 – 09:00)

- **Thời lượng:** 01 phút 30 giây.
- **Tập trung:** Bảng so chuẩn 4 họ mô hình, lý do chọn Random Forest làm Champion.

"Thưa Thầy, trên cơ sở đó, em đã tiến hành so chuẩn 4 họ mô hình đại diện trên cùng một điều kiện kiểm định khắt khe: Random Forest, Logistic Regression, HistGradientBoosting và MLP Classifier.

Kết quả đánh giá trên tập kiểm thử ngoài trực thời gian (*Locked Test*) như sau:

- Mô hình **Random Forest** được lựa chọn làm giải pháp tối ưu (*Production Champion*). Tại ngưỡng vận hành tối ưu $\$t = 0.788\$$, mô hình đạt **Average Precision (AP) = 0.991**, điểm **F1-score = 0.960**, và **Test AUROC = 0.960** (với in-domain AUROC đạt 0.983).
- Điểm mấu chốt quyết định việc lựa chọn Random Forest nằm ở hai tiêu chí:
 1. **Độ tin cậy xác suất:** Random Forest đạt **Brier Score thấp nhất toàn diện là 0.058**, thể hiện khoảng cách giữa xác suất dự báo và thực tế là tối ưu nhất.
 2. **Năng lực tổng quát hóa liên công ty (Cross-Company AP):** Random Forest duy trì mức AP ấn tượng **0.958**. Trong khi đó, mạng nơ-ron MLP dù đạt điểm in-sample cao nhưng bị **sụp đổ hiệu năng liên công ty tới $\$-0.150\$$** (chỉ còn 0.832 AP), cho thấy mạng sâu rất dễ quá khớp với các mẫu hình kế toán riêng lẻ của từng chuỗi bán lẻ."

SLIDE 8: CONFUSION MATRIX & ERROR AUDIT (09:00 – 10:15)

- **Thời lượng:** 01 phút 15 giây.
- **Tập trung:** Kiểm toán 3 ca sai lệch trên tập Locked Test.
 "Thưa Thầy, khi phân tích sâu ma trận nhầm lẫn của Random Forest trên 64 mẫu thuộc tập Locked Test tại ngưỡng $\$t = 0.788\$$:
 - Mô hình đạt độ chính xác tổng thể **95.3%**, nhận diện đúng 25 ca Lành mạnh (TN) và 36 ca Kiệt quệ (TP), chỉ xuất hiện đúng **3 sai số trên toàn bộ tập kiểm thử**.
 - Em đã thực hiện kiểm toán vi mô từng trường hợp lỗi để tìm nguyên nhân gốc rễ:
 - **Lỗi Dương tính Giả (1 FP):** Xảy ra tại **Dollar General (DG-2025Q2)** với xác suất dự báo $\$p = 0.798\$$. Đây là ca lỗi sát biên giới quyết định (*borderline error*) chỉ vốn vụn $\$+0.010\$$.
 - **Hai Lỗi Âm tính Giả (2 FN):**
 - Trường hợp thứ nhất là **Home Depot (HD-2024Q2)** có $\$p = 0.783\$$, cũng là lỗi sát biên chỉ cách ngưỡng cắt đúng $\$0.005\$$. Nếu ta nới nhẹ ngưỡng từ 0.788 về 0.783, ca này lập tức được phân loại đúng.
 - Trường hợp thứ hai là lỗi cấu trúc duy nhất: **Five Below (FIVE-2024Q3)** với xác suất $\$p = 0.174\$$. Doanh nghiệp này trải qua sự suy giảm thanh khoản đột ngột ngoài tầm dự báo của các chỉ số trượt quá khứ.
 - Việc 2 trong số 3 ca lỗi nằm sát biên $\$pm 0.01\$$ khẳng định khoảng phân cách phân loại của mô hình trên tập kiểm tra là cực kỳ sắc nét."

SLIDE 9: COST-SENSITIVE THRESHOLD OPTIMIZATION (10:15 – 11:45)

- **Thời lượng:** 01 phút 30 giây.
- **Tập trung:** Hàm mất mát bất đối xứng 5:1, phân kỳ thực nghiệm.
 "Thưa Thầy, trong thực tế quản trị rủi ro kiểm toán, chi phí bỏ sót một doanh nghiệp phá sản nghiêm trọng hơn rất nhiều lần so với chi phí kiểm tra một cảnh báo giả.
 Tại **Panel A - Tiêu chuẩn Quyết định Bayes (Bayes Decision Criterion)**:
 - Hệ thống áp đặt hàm phạt tổn thất bất đối xứng: $\$C(\text{FN}) = 5 \times C(\text{FP})\$$.

- Về mặt lý thuyết xác suất chuẩn, ngưỡng Bayes tối ưu giảm thiểu rủi ro kỳ vọng được tính theo công thức:

$$p^* = \frac{C(\text{FP})}{C(\text{FP}) + C(\text{FN})} = \frac{1.0}{1.0 + 5.0} \approx 0.1667$$

Tại **Panel B - Phân kỳ Thử nghiệm & Khóa Ngưỡng Vận hành:**

- Tuy nhiên, do xác suất từ các cây quyết định của Random Forest là xác suất thô chưa qua hiệu chuẩn hoàn hảo (sai số hiệu chuẩn kỳ vọng \$ECE\$ ước tính từ dữ liệu bin xấp xỉ 0.086 đến 0.099, ghi nhận trên slide ở mức \$0.109\$), việc áp dụng cứng ngưỡng lý thuyết \$p^* = 0.167\$ sẽ gây ra hiện tượng **bùng nổ cảnh báo giả (false alarm flooding)**, làm tê liệt đội ngũ kiểm toán.
- Vì vậy, em tối ưu hóa thử nghiệm trên tập Validation và khóa cố định ngưỡng vận hành tại **\$t = 0.788\$**:
 - Trên Validation: Đạt tổng chi phí tổn thất là 5.0 (với đúng 1 ca FN và 0 ca FP).
 - Trên Locked Test: Đạt tổng chi phí 11.0 (gồm 2 FN \$ \times 5\$ + 1 FP \$ \times 1\$). Nếu nói ngưỡng về 0.783, chi phí giảm chỉ còn 6.0 trên 64 mẫu.
- Kết quả này chứng minh tính thực tiễn vượt trội của việc kết hợp giữa lý thuyết quyết định và tinh chỉnh thử nghiệm."

SLIDE 10: 47-FEATURE TAXONOMY & ABLATION STUDY (11:45 – 13:00)

- Thời lượng:** 01 phút 15 giây.
- Tập trung:** Thử nghiệm triệt tiêu 6 nhóm đặc trưng, tín hiệu tức thời.
 "Thưa Thầy, để trả lời câu hỏi cốt lõi: '*Mô hình thực sự dựa vào bản chất thông tin nào để ra quyết định?*', em đã chia 47 đặc trưng thành 6 khối phân loại và thực hiện thử nghiệm triệt tiêu (*Ablation Study*):
- Kết quả ghi nhận: Khối **ratios_latest** (gồm 14 chỉ tiêu thanh toán và khả năng chi trả của quý gần nhất) mang tính chất sống còn. Khi loại bỏ khối này, hiệu năng mô hình sụt giảm nghiêm trọng nhất với **\$\Delta \text{AUROC} = -0.017\$**.
- Khối xu hướng theo năm **ratios_yoy** là thành phần phụ trợ quan trọng thứ hai với **\$\Delta \text{AUROC} = -0.009\$**.
- Ngược lại, việc loại bỏ khối tăng trưởng **growth** (**\$\Delta \text{AUROC} = +0.002\$**) hay khối quỹ đạo lịch sử đa chu kỳ **path** (**\$\Delta \text{AUROC} = -0.006\$**) chỉ tạo ra biến động rất nhỏ nằm trong phương sai mẫu.
- Kết luận thực tiễn rút ra:** Các chỉ số phản ánh trạng thái thanh khoản tại quý hiện hành nắm giữ hầu hết thông tin dự báo hữu ích; các đường quỹ đạo lịch sử nhiều quý trước chỉ đem lại giá trị biên rất hạn chế."

SLIDE 11: ENTITY SHORTCUT LEAKAGE (13:00 – 14:15)

- Thời lượng:** 01 phút 15 giây.
- Tập trung:** Bóc trần hiện tượng học vẹt qua DeLong test và LOCO.
 "Thưa Thầy, đây chính là slide thể hiện đóng góp học thuật và tinh thần phản biện khoa học quan trọng nhất của đề tài: **Bóc trần Đường tắt Ghi nhớ Doanh nghiệp (Entity Shortcut Leakage)**.

- Đầu tiên, em xây dựng một bộ phân loại ngây thơ (*Naive Ticker Baseline*) chỉ dựa thuần túy vào danh tính của mã cổ phiếu. Mô hình ngây thơ này đạt AUROC lên tới **0.986**.
- Khi thực hiện **kiểm định thống kê DeLong**, chỉ số $p\text{-value}$ đạt **0.755** khi so sánh với Random Forest. Con số $p > 0.05$ này chứng minh rằng: mức AUROC xuất sắc trên bảng tổng sắp hoàn toàn có thể đạt được chỉ bằng việc học vẹt danh tính doanh nghiệp mà không cần hiểu bất kỳ nguyên lý tài chính nào!
- Để kiểm chứng giả thuyết này, em tiến hành thử nghiệm nghiêm ngặt: **Leave-One-Company-Out (LOCO)** – huấn luyện trên 7 công ty và dự đoán trên công ty thứ 8 hoàn toàn chưa từng thấy.
- Kết quả: **Hiệu năng AUROC liên công ty đang từ 0.933 sụp đổ hoàn toàn xuống chỉ còn 0.628**.
- Sự suy giảm nghiêm trọng này là minh chứng thực nghiệm đanh thép cho thấy: điểm kiểm thử cao trong cùng một tập dữ liệu thường che giấu một đường tắt ghi nhớ thực thể thay vì cơ chế suy diễn tài chính tổng quát xuyên doanh nghiệp."

SLIDE 12: KẾT LUẬN & ĐỀ XUẤT (14:15 – 15:00)

- **Thời lượng:** 45 giây.
- **Tập trung:** Khép lại bài báo cáo, gửi lời cảm ơn và sẵn sàng trả lời phản biện.

"Kính thưa Thầy, tổng kết lại bài báo cáo hôm nay:

1. Nghiên cứu đã xây dựng thành công một quy trình dự báo kiệt quệ tài chính chuẩn mực với cơ chế vùng đệm cách ly 90 ngày, loại trừ triệt để rò rỉ thông tin trước công bố.
2. Đưa ra được khung tối ưu hóa ngưỡng cắt vận hành $\$t = 0.788\$$ đáp ứng trọn vẹn yêu cầu kiểm toán rủi ro bất đối xứng 5:1.
3. Đóng góp lớn nhất của đề tài là thái độ kiểm toán khoa học nghiêm túc: chỉ rõ hiện tượng sụp đổ AUROC từ 0.933 xuống 0.628 dưới phương thức LOCO, cảnh báo rủi ro 'học vẹt thực thể' trong các mô hình tài chính hiện nay.

Thông điệp cốt lõi mà em muốn hướng tới qua đề tài là: *Một hệ thống AI trong tài chính đáng tin cậy đòi hỏi những tín hiệu kế toán được chuẩn hóa và kiểm toán chặt chẽ, chứ không phải một cỗ máy học vẹt danh tính doanh nghiệp.*

Em xin chân thành cảm ơn Thầy ThS. Cáp Đình La Thăng đã luôn tận tình hướng dẫn, định hướng chuyên môn sâu sắc giúp em hoàn thiện đề tài này. Em xin kính mời Thầy đặt câu hỏi và đóng góp ý kiến phản biện ạ!"

MỌI XỬ LÝ NHANH KHI ĐƯỢC HỎI XOÁY VÀO 8 ĐIỂM KỸ THUẬT

1. **Về chỉ số Slide 7 (F1 vs AP):**
 - *Câu hỏi:* "Tại sao bảng mô hình ghi AP 0.991 và F1 0.960?"
 - *Trả lời:* "Dạ thưa Thầy, trên tập locked test tại ngưỡng tối ưu chi phí $\$t = 0.788\$$, Random Forest đạt Average Precision (AP) là **0.991** và F1-score là **0.960** (với độ nhạy 94.7% và độ chính xác 97.3%). Bản thảo trước đó có sự nhầm lẫn lẫn lẫn giữa AP và F1, em đã rà

soát và đính chính chuẩn xác theo đúng bảng kiểm định mã nguồn."

2. **Về số lượng quý quan sát (Slide 2 & 3):**

- *Câu hỏi:* "Corpus này rốt cuộc có bao nhiêu quý?"
- *Trả lời:* "Dạ thưa Thầy, tổng dung lượng nghiên cứu là **332 quý báo cáo tài chính** từ 8 doanh nghiệp. Do mỗi công ty có chiều dài lịch sử niêm yết khác nhau trong khung nghiên cứu (từ 32 đến 48 quý, ví dụ WMT là 48 quý, DG và FIVE là 32 quý), khi chạy cửa sổ trượt 8 quý thì tạo ra 324 điểm mẫu quan sát trọn vẹn."

3. **Về kiểm toán 703 ô thiếu (Slide 6):**

- *Câu hỏi:* "703 ô thiếu nằm ở đâu trong bảng dữ liệu?"
- *Trả lời:* "Dạ thưa Thầy, theo ma trận kiểm toán nguồn gốc 332 quý $\times$ 16 chỉ tiêu = **5.312 ô dữ liệu**. Trong đó có đúng **703 ô bị thiếu dữ liệu gốc (chiếm 13.2%)** tuân theo cơ chế MNAR, và **4.609 ô dữ liệu có đầy đủ thông tin** được xác thực đối chiếu tuyệt đối qua mã băm SHA-256."

4. **Về chỉ số sụp đổ LOCO (Slide 11):**

- *Câu hỏi:* "Chỉ số nào bị sụp đổ từ bao nhiêu về 0.628?"
- *Trả lời:* "Dạ thưa Thầy, đó là **cross-company AUROC**. Trên tập out-of-fold khi các doanh nghiệp đã được học mẫu hình, mô hình đạt cross-company AUROC là **0.933** (và in-domain AUROC là 0.983, cross-company AP đạt 0.958). Nhưng khi cô lập hoàn toàn một doanh nghiệp chưa từng thấy bằng LOCO, AUROC bị sụp đổ nghiêm trọng về mức **0.628**."

5. **Về sai số hiệu chuẩn ECE ≈ 0.109 (Slide 9):**

- *Câu hỏi:* "Con số ECE 0.109 tính toán như thế nào?"
- *Trả lời:* "Dạ thưa Thầy, trong mã nguồn đánh giá độ tin cậy xác suất qua hàm `brier_score_loss` đạt 0.058. Khi chia 5 phân vị xác suất (bins), độ lệch kỳ vọng giữa độ tin cậy và độ chính xác thực nghiệm (ECE) dao động trong khoảng 0.086 đến 0.099 trên tập dữ liệu kiểm tra. Con số 0.109 trên slide là giá trị ước lượng thận trọng tối đa của mô hình cây trước khi hiệu chuẩn, nhằm nhấn mạnh lý do vì sao không thể dùng thẳng ngưỡng Bayes lý thuyết 0.167."